

RAG + Agent Framework

Generación Aumentada por Recuperación con Azure AI y Microsoft Agent Framework

CREDICORP

Datos elaborados por BCP para uso Interno

Agenda

01

El Problema y la Solución: ¿Qué es y qué resuelve RAG?

02

Los Componentes Clave & Fundamento Matemático Bayesiano

03

Técnicas de Precisión: Búsqueda Híbrida y Semantic Reranker

04

RAG Agéntico: Integración con Microsoft Agent Framework en Azure

05

Demo en Vivo: Explorando el cráter Jezero con documentos de la NASA



El Desafío de los LLMs

Límites de los Modelos de Lenguaje Aislados

Corte de Conocimiento (Knowledge Cutoff):

Los modelos solo saben lo que aprendieron durante su entrenamiento. No conocen tus datos de hoy.

Alucinaciones:

Cuando un modelo no sabe la respuesta, tiende a inventar datos con absoluta seguridad sintáctica.

Falta de Trazabilidad:

No pueden citar la página, el memorándum o el documento oficial de donde extrajeron el dato.

Costo y Lentitud de Reentrenar:

Hacer fine-tuning o reentrenar continuamente es inviable técnica y económicamente para datos vivos.

 [RECURSO VISUAL SUGERIDO]

Robot LLM vs. Documentos Vivos 2026

Ilustración dividida en 2 paneles: en la izquierda, un robot LLM mirando un calendario vencido ('Entrenado en 2024') respondiendo con signos de interrogación y alucinaciones; a la derecha, una pila de documentos confidenciales y actualizados de 2026 a los cuales el LLM no tiene acceso por estar aislado.

Fundamentos de RAG

Retrieval-Augmented Generation (Generación Aumentada por Recuperación)



[RECURSO VISUAL SUGERIDO]

Flujo Conceptual RAG en 3 Pasos

Diagrama de flujo conceptual en 3 pasos: (1) Usuario pregunta -> (2) Base de datos documental filtra y extrae 3 fichas de texto relevantes -> (3) El LLM recibe la pregunta + las 3 fichas y entrega una respuesta fundamentada con etiquetas de citas numéricas [Doc1, Pág 4].

La Analogía del Examen:

Un examen tradicional de memoria vs. un examen a libro abierto con un índice perfecto.

¿Cómo funciona el flujo RAG?

1. Retrieval: Recupera fragmentos relevantes de la base documental.
2. Augmentation: Inyecta los fragmentos como contexto en el prompt.
3. Generation: El LLM genera la respuesta citando fuentes.

Beneficios Inmediatos:

Grounding garantizado, citas trazables, actualización instantánea de documentos y cero reentrenamiento.



Arquitectura del Pipeline

De Documentos Crudos a Respuestas con Grounding

1. Chunking (Fragmentación):

División de PDFs largos en fragmentos de 500-1000 tokens con solapamiento (overlap) para preservar el contexto.

2. Embeddings (Vectorización):

Transformación de texto en vectores numéricos de 1536 dimensiones que capturan la semántica.

3. Vector Store & Search Index:

Almacén especializado (Azure AI Search) con índices HNSW para búsqueda rápida por similitud coseno.

4. Grounded Prompting:

Instrucciones estrictas al LLM para responder únicamente con base en la evidencia provista sin extrapolar.

 [RECURSO VISUAL SUGERIDO]

Pipeline de Ingesta y Vectorización

Infografía horizontal: Documento PDF -> Cuchilla de corte (Chunking con overlap) -> Modelo de Embedding (convertidor texto a números) -> Espacio vectorial 3D de puntos -> Retriever -> Prompt final con contexto enriquecido.

Fundamento Matemático

RAG expresado formalmente como Inferencia Bayesiana

Generación Clásica (Paramétrica):

El modelo depende únicamente de sus pesos fijos θ . Riesgo alto de alucinación si el dato no fue memorizado.

$$P(y | x) = \prod_{t=1}^T P(y_t | y_{<t}, x; \theta)$$

Generación Aumentada (Inferencia No Paramétrica):

- $P(d | x)$: Prior de relevancia del documento d (Retriever)

$$P(y | x) = \sum_{d \in \mathcal{D}} P(d | x) \cdot P(y | x, d; \theta)$$

- $P(y | x, d)$: Likelihood de la respuesta con evidencia (Generator)

- La evidencia 'd' colapsa la entropía y enfoca la probabilidad en la verdad factual.

 [RECURSO VISUAL SUGERIDO]

Colapso de Incertidumbre y Distribución Condicionada

Gráfico comparativo matemático: a la izquierda, una distribución de probabilidad difusa y dispersa (modelo estándar aislado); a la derecha, la distribución condicionada bayesiana que se estrecha y enfoca hacia la verdad cuando se incorpora la evidencia observable d , mostrando la reducción drástica de la entropía.

Estrategias de Recuperación

¿Por qué los vectores puros no son suficientes?

Búsqueda Léxica (BM25):

Excelente para códigos exactos, siglas, números de parte (ej. 'Curiosity RTG-04').
Falla en sinónimos.

Búsqueda Vectorial (Semántica):

Excelente para conceptos e intenciones (ej. 'buscar vida' -> 'biofirmas'). Falla en términos específicos o raros.

Búsqueda Híbrida + RRF (Best of Both Worlds):

Ejecuta BM25 y Dense Vectors en paralelo combinando los rankings mediante Reciprocal Rank Fusion para una lista balanceada.

$$\text{RRF_Score}(d) = \sum_{m \in M} \frac{1}{k + r_m(d)}$$

 [RECURSO VISUAL SUGERIDO]

Convergencia Híbrida BM25 + Vectores (RRF)

Diagrama con dos caminos convergentes: Camino Superior (BM25 Keyword Search) y Camino Inferior (Dense Vector Search) que procesan la misma consulta y convergen en un nodo central 'Reciprocal Rank Fusion' que entrega una lista unificada y balanceada de candidatos.

La Pieza Crítica: Semantic Reranker

Transformando candidatos crudos en evidencia de alta calidad



[RECURSO VISUAL SUGERIDO]

Embudo de Relevancia: Top 50 a Top 3

Diagrama de embudo en dos fases: Fase 1 (Primer nivel rápido): De 100,000 documentos a Top 50 usando Búsqueda Híbrida -> Fase 2 (Semantic Reranker / Cross-Encoder): Reordena los 50 y coloca exactamente en el Top 3 los documentos con mayor relevancia semántica real hacia el LLM.

El Dilema: Velocidad vs. Precisión:

Los Bi-Encoders (vectores) filtran 1,000,000 de docs a 50 en milisegundos, pero comparan textos de forma independiente.

Cross-Encoder / Semantic Reranker:

Evalúa la pregunta y el fragmento juntos mediante Cross-Attention profunda, entendiendo negaciones y matices contextuales.

Impacto en Producción:

Evita que fragmentos irrelevantes contaminen el contexto del LLM y garantiza que el Top 3 contenga la respuesta exacta.



RAG Agéntico

Integración con Microsoft Agent Framework (MAF)

RAG Tradicional (Pipeline Rígido):

Siempre consulta la base vectorial obligatoriamente, incluso ante saludos o preguntas generales, gastando cómputo innecesario.

RAG con Agente (Tool Calling & Razonamiento):

El agente utiliza la búsqueda como una herramienta (Search Tool):

- Conversación general -> Responde de inmediato.
- Pregunta técnica -> Invoca Azure AI Search.
- Resultado insuficiente -> Reformula la consulta automáticamente.



[RECURSO VISUAL SUGERIDO]

Orquestación de Agente y Catálogo de Tools

Ilustración de la arquitectura de Microsoft Agent Framework: Agente con LLM en el centro conectado a un catálogo de herramientas (Tool: Azure AI Search, Tool: Calculadora, Tool: CRM). El agente evalúa la intención del usuario y decide si activa o no la herramienta de recuperación de documentos.

Mejores Prácticas de Ingeniería

Estrategias aplicadas en la Fase 04 - Transit



[RECURSO VISUAL SUGERIDO]

Los 4 Pilares de un RAG Empresarial

Cuadrícula de 4 iconos modernos con tarjetas visuales: (1) Filtro de Metadatos [Misión: Mars2020], (2) Escudo de Seguridad / Fallback contra alucinaciones, (3) Transmisión de texto en tiempo real (Streaming SSE), (4) Tarjeta de Citas con badge de confianza (Score 98%).

Filtrado por Metadatos:

Etiquetado de chunks (misión, fecha, categoría) para segmentar búsquedas antes del cálculo de similitud.

Control de Alucinaciones (Fallback):

Umbral de confianza estrictos: si la evidencia es insuficiente, el agente declara honestamente que no dispone del dato.

Streaming de Respuestas (SSE):

Transmisión de tokens en tiempo real mejorando la latencia percibida por el usuario final.

Trazabilidad & Citas Interactivas:

Cada respuesta incluye enlaces directos al documento PDF, número de página y score de confianza.



Arquitectura del Proyecto

Ecosistema Cloud: Azure AI Foundry + Search + FastAPI + Next.js

Almacenamiento e Ingesta:

PDFs oficiales de la NASA en Azure Blob Storage procesados mediante Azure AI Search Indexer.

Motor de Búsqueda:

Azure AI Search con índice híbrido HNSW vectorial + BM25 + Semantic Reranker activo.

Cerebro y Orquestación:

Microsoft Agent Framework en backend FastAPI conectando Azure OpenAI (GPT-4o y Text-Embedding-3).

Experiencia de Usuario:

Frontend en Next.js con explorador de chunks, comparador de rerank y chat conversacional.



[RECURSO VISUAL SUGERIDO]

Arquitectura End-to-End Cloud y On-Premise

Diagrama de arquitectura cloud de extremo a extremo: Azure Blob Storage -> Indexer & Skills de Azure AI Search -> Índice Híbrido -> Backend FastAPI (Microsoft Agent Framework) -> Frontend Next.js con panel de control de documentos y chat.

Con estos conceptos claros, veamos a RAG y a nuestro agente en acción sobre las misiones a Marte.



Casos de Prueba en la Demo

Lo que demostraremos en vivo

Caso 1: Búsqueda Semántica Conceptual:

Pregunta sin palabras exactas ('¿Qué experimentos buscan biofirmas fósiles?') -
> Encuentra Perseverance y Mars 2020.

Caso 2: El Poder del Semantic Reranker (Cráter Jezero):

- Sin Rerank: Se mezclan fragmentos de Phoenix/Curiosity y el agente reporta falta de evidencia.
- Con Rerank: Los fragmentos de Mars 2020 suben al #1 y la respuesta es 100% precisa.

Caso 3: Pregunta Fuera de Dominio (Out of Corpus):

Pregunta ajena ('¿Cuál es el menú del comedor de la NASA?') -> El agente reconoce límites sin alucinar.

 [RECURSO VISUAL SUGERIDO]

Interfaz de la Demo (Next.js + FastAPI)

Captura de pantalla dividida de la aplicación web: Panel izquierdo mostrando la comparativa de chunks con vs sin Rerank; Panel derecho mostrando la respuesta final del agente con citas interactivas y badges de confianza.

#ComunidadIA

CREDICORP

¡Ayúdanos a potenciar los MIÉRCOLES DE IA!

Tu opinión es clave para
seguir aprendiendo
juntos. 🚀



PONLE IA A TU DÍA